운영 체제

CH 0.

DAY-1

- 기본적인 동작

  1) 파일의 내용을 저장할 공간을 할당 받고 저장. (= Disk Block, 일반적으론 4kb 단위)

  2) Disk에 inode라는 파일의 정보(만들어진 시간, 사람, 접근 제어 정보 등)을 담고 있는 공간을 할당 받음.

  3) Inode와 파일을 연결함

  4) 컴파일러를 통해 파일을 수행 가능한 바이너리 파일(0,1로 이루어진 파일)로 만듦.

  5) 바이너리 파일을 실행할 때에는 task라는 객체를 만듦.

  6) task라는 객체를 만들기 위해 바이너리 파일을 우선 RAM에 load함.

  7) Task는 RAM의 일부 공간(page frame)을 할당 받고 관리.

  8) 기존에 존재하던 task들과 경쟁하며 CPU를 할당받기 위해 노력함.

  9) 운영체제는 이런 task들에게 CPU를 할당해줌. (대표적으로 Round-Robin[1] 방식이 유명)

- 임베디드 부팅을 위해선 3개의 파일이 필요하다.

  1) Boot loader: 장치들을 초기화해주고 커널, 파일 시스템을 램에 복사해주는 기능

  2) Kernel: 프로그램에 대한 자원 할당을 담당한다. 인터럽트 처리기와 스케줄러 등을 포함한다. 주기억장치에 저장된다.

     zImage와 uImage는 리눅스 커널 중 하나다. uImage는 zImage의 특정 명령어를 압축한 것이다.

  3) 하나의 압축 파일로, 기본적인 명령어, 라이브러리 파일을 압축하여 파일 시스템으로 만든다.

[1] 일정시간 동안 한 task가 CPU를 사용하고 시간이 지나면 다음 task가 사용하는 방식

- Daemon: 한번만 실행해 놓으면 지속적으로 동작하는 프로그램 또는 명령어
- Shell: 이용자와 시스템 사이의 대화를 가능하게 해주는 명령 해석기. 이용자가 입력한 문장을 읽어, 그 문장이 요청하는 시스템 기능을 수행하게 해준다. Kernel과 달리 보조 기억장치에도 저장이 될 수 있다.
- Idle 상태: 하드웨어 장치에서 다음 수행 명령을 기다리는 동안 별다른 작업을 수행하지 않고 기다리는 상태
- Super Block: 유닉스 시스템에서 파일 시스템의 상태를 설명하는 블록
- metadata: 다른 데이터를 설명해주는 데이터. Contents의 위치와 내용, 작성자 정보, 이용조건, 내력 등이 담겨있다. metadata는 보통 데이터를 표현하기 위한 목적과 데이터를 더 빠르게 찾기 위한 목적이 있다.

CH1.

- Microkernel[2]: 운영체제의 기본적인 기능을 제공하는 kernel만 남기고 소형화한 것.
- Linux는 monolithic structure[3]를 기반으로 설계되었다. (실제로 kernel 자체는 monolithic이지만 파일 시스템, 디바이스 드라이버, 스케줄링 등 여러 부분에서 모듈을 지원하기에 하이브리드라고 볼 수 있다.)

[2] Windows NT, Mac OS에서 사용

[3] 모듈화와는 다르게 독립성이 없는 소프트웨어 블록들의 집합으로 이루어진 소프트웨어.

Monolithic는 최적화에 좋고, 속도가 빠르며, 경로를 단축시킬 수 있지만 유지보수가 힘들다.

CH2.

Day-2

- OS = resource manager (system call을 통해 task가 resource를 활용할 수 있게 해준다.)
  1) Physical resource

     CPU, Memory, Disk, terminal, network 등 시스템 구성요소와 주변 장치
  2) Abstract resource (matched with physical)

     물리적 자원을 관리하기 위한 추상화 객체들

     Ex) task, memory segment, page, protocol, packet
  3) Abstract resource (Not matched with physical)

     Security, ID access control

- Kernel
  1) task manager

     task의 생성, 실행, 상태 전이, 스케줄링, 시그널 처리, 프로세스 간 통신 지원
  2) memory manager

     Segment[4]와 page[5] 관리
  3) filesystem

     파일 생성, 접근 제어, inode 생성, 디렉터리 관리, super block 관리
  4) network manager

     네트워크 장치를 socket으로 제공, TCP/IP 같은 통신 프로토콜
  5) device driver manager.

     주변 장치를 일관되게 접근하도록 해줌

---

[4] 주 기억장치에 load되는 프로그램 분할의 기본 단위

[5] 프로그램을 한번에 처리할 수 있는 단위. Page 단위로 주 기억 장치에 로드하고 언로드한다.

- gcc는 GNU의 Complier다.

  Preprocessor, complier, assembler, linker 과정을 통해, 실행파일을 생성할 수 있다.

  Preprocessor는 전처리 지시자들을 해석하고, complier는 high level language를 .s 형태의 어셈블리어 형태로 전환한다. Assembler는 .s 파일을 .o 형태의 object file로 변환한다. Linker는 생성된 object file들을 .out 형태의 execute file로 만든다.

  - Symbol은 주소를 갖는 최소 단위로, 크게 RO, RW, ZI 부분으로 나뉜다. RO부분은 보통 ROM에 담기는 것으로 code(function), const variable등이 포함된다. RW는 global variable 중 초기화가 된 variable을 포함한다. ZI은 0으로 초기화가 되거나 초기화가 되지 않은 global variable이다. 그리고 static이 아닌 local variable들은 ZI(stack이나 heap)에 자리잡는다.

  - Object file의 크게 .text, .data, .bss section으로 구성되어 있다. .text는 RO, .data는 .RW, .bss는 ZI에 해당한다. Linker를 이용하여 ELF file을 만들 때, 각 object file의 section들끼리 묶여, ELF file의 segment가 된다. 다른 object file에서 참조한 변수나 코드들을 .rel.data나 .rel.text 등으로 linker될 때 relocate되어 연결된다. ELF format은 RO segment의 segment header table을 시작으로 .init, .text, .rodata로 구성되어 있고, RW segment의 .data, .bss 부분, 메모리에 load되지 않는 .symtab(symbol table), .debug, .line, .strtab, object file의 section을 설명하는 section header table로 구성되어 있다.

- Makefile

  파일간의 종속관계를 나타낸 것으로 컴파일러가 순차적으로 실행될 수 있게 해준다.

  Make를 쓰게되면 프로그램의 종속 구조를 파악하기 쉽고, 반복 작업의 최소화가 가능하다.

  Target, dependency, command, macro로 구성되며, 코드를 단순화시키고, 수정을 용이하게 하기 위해 macro를 사용한다.

CH3

DAY-3

- Program과 process

  - Process는 동작중인 program이다. 디스크에 저장되어 있는 program(파일 형태)이 kernel로부터 자원을 할당 받아 동적인 객체가 된 것이 process라고 할 수 있다.

- Process의 구조

  Process의 생김새는 가상 주소[6] 공간에서의 모양을 의미한다. 프로세스는 크게 text, data, heap, stack 부분으로 나눌 수 있다. User space에서 text(함수, instruction 등)는 제일 하위 주소 공간을 차지하고, 그 다음 data(glob var), heap, stack 순으로 차지한다. Local 변수는 stack에, dynamic var는 heap에 동적으로 할당되는데, stack는 kernel, user space의 경계면에서 아래로 커지고 heap은 위로 커진다. 각 영역을 segment 또는 vm_area_struct(가상 메모리 객체)라고 한다.

- Process의 생성

  Process는 fork()와 vfork()로 생성된다.

  - fork()

    fork()는 자식 프로세스를 생성하고, 메모리 영역을 할당하여, 부모 프로세스의 메모리 공간을 모두 복제한다. 하지만 모두 복제하는 것은 비효율적이기 때문에 최근에는 COW 방식으로 기본적으로는 메모리 공간을 참조만 하고 있다가 변경이 확인되면 복제하는 방식으로 변했다. 부모 프로세스와 자식 프로세스는 변수를 공유하지 않는다. fork()는 자식 프로세스가 생성되면, 부모 프로세스에는 자식 프로세스의 PID[7]

---

[6] 한정된 RAM의 한계를 극복하고자 disk같은 보조 저장 장치를 이용해, 디스크 공간을 메모리처럼 활용할 수 있게 해주는 기법이다. Disk에 존재하는 파일을 paging file이라고 하며, process는 가상 주소를 사용하고, 읽고 쓸 때만 MNU를 사용해 물리주소로 변환한다. Process가 RAM의 공간을 초과해, disk를 사용할 때는 물론, 성능이 저하된다. Thread는 각 process에 할당된 주소 공간에만 접근할 수 있다.

가상메모리는 kernel space와 user space로 나뉘는데 kernel space는 kernel, driver 등을 실행시키기 위한 예비 메모리고 user space는 process에 할당되는 공간이다.

[7] Process ID

를, 자식 프로세스에는 0을 반환한다. 에러 시에는 적당한 에러 값을 반환한다.

- vfork()

  fork() 함수는 주로 fork 뒤에 exec()를 실행함으로써 자식과 부모 프로세스를 동시에 실행하는 경우가 많다. 하지만 이럴 경우 불필요한 복제가 일어나기 때문에 오버헤드가 일어날 경우를 위해 vfork()를 사용한다. vfork()는 부모의 메모리 공간을 공유한다. 따라서 부모와 자식이 변수를 공유한다. 따라서 부모와 자식의 race condition을 막기 위해 자식 프로세스가 생기면 부모 프로세스는 sleep된다. vfork()뒤에 바로 exec() 계열 함수를 호출하지 않으면 자식 프로세스에서 변경한 변수가 부모 프로세스에도 적용된다는 위험성이 있다.

- clone()

  쓰레드를 생성하는 함수. fork()는 별도의 메모리 공간을 할당한 뒤 부모 프로세스의 영역 값을 복사하지만 clone()는 메모리 자체를 공유한다. clone()으로 생긴 프로세스의 값 변경이 부모 프로세스에도 적용이 되므로 쓰레드라 봐도 무방하다.

- exec()

  exec() 함수는 사용하던 메모리 공간을 해제하고 새로운 실행파일을 로드하고 실행한다. 즉 exec()를 호출한 프로세스는 실행이 중지되고 새로운 프로세스로 교체된다.

- 한 프로세스에 여러 쓰레드가 동작할 수 있다. 이런 모델을 다중 쓰레드 시스템이라 하는데 쓰레드의 생성은 프로세스의 생성보다 resource가 적게 든다. 하지만 자식 쓰레드에서의 결함이 부모 쓰레드로 전파가 된다는 단점이 있다. 따라서, 쓰레드 모델은 지원 공유에 적합하고, 프로세스 모델을 결함 고립에 적합하다.

DAY - 4

- Linux task model

  프로세스는 자원과 자원에서 수행되는 수행 흐름으로 구성된다. 이를 관리하기 위해 task_struct라는 자로 구조를 생성한다. 리눅스 커널은 프로세스와 쓰레드 모두 task_struct로 관리한다. 프로세스와 쓰레드는 task_struct에서 해석의 여부에 차이가 있다. 리눅스에서는 프로세스와 쓰레드를 모두 task라는 객체로 관리한다.

  리눅스에서는 fork(), vfork(), clone()을 이용해서 프로세스와 쓰레드를 생성한다. fork()와 clone()은 커널의 sys_clone()을, vfork()는 sys_vfork() 시스템 호출을 사용한다. sys_clone()과 sys_vfork() 모두 커널 내부 함수인 do_fork()를 호출한다. 리눅스에선 프로세스와 쓰레드 모두 task를 생성하기 때문인데 do_fork()의 인자로 부모 태스크와의 관계를 지정해, fork()와 clone()을 구별한다.

  ■ do_fork()

    do_fork()는 우선적으로 task_struct를 구성한다. Task의 이름, 부모 task 등을 기록한다. 그 후 task에 자원을 할당한 뒤 수행 가능한 상태로 만들어준다.

  Task는 task만의 유일한 id인 PID가 있다. 하지만 한 프로세스 내의 쓰레드는 같은 ID를 공유해야 하는데 이것을 위해 tgid(thread group id)라는 개념이 있다. Task가 처음 생성되면 유일한, PID값을 같게 된다. 여기서 쓰레드면 tgid값에 부모 쓰레드의 PID값을 넣어주고 프로세스면 새로 할당된 PID값을 tgid에 넣어주게 된다.

  결과적으로 fork()와 vfork()는 부모 태스크와 pid, tgid가 다르고 clone()은 부모 태스크와 pid는 다르지만 같은 tgid를 가진다.

- task context

  ■ Context: 태스크와 관련된 모든 정보를 말한다. 태스크 우선순위, CPU 사용량, 태스크 간의 관계, 시그널, 사용 자원, file descriptor 등을 의미한다. Task context는 크게 세가지로 나눌 수 있다.

  1) System context

     태스크의 정보를 유지하기 위해 커널이 할당한 자료구조.

     Task_struct, file descriptor, file table, segment table, page table 등이 있다.

  2) Memory context

     Text, data, stack, heap, swap 공간이 포함된다.

  3) Hardware Context

     문맥 교환을 할 때 수행 현재 실행 위치에 대한 정보를 저장한다.

     태스크가 대기 상태나 준비 상태로 전환될 때 다음에 실행될 부분을 저장해둔다.

- task_struct

  1) task identification

     태스크를 인식하기 위한 변수들이 있다. PID, TGID, 해쉬.

     또한 audit_struct를 통해 태스크에 대한 사용 접근 권한을 제어하는 UID, EUID, SUID, FSUID등과 사용자 그룹에 대한 접근 관리인 GID, EGID, SGID, FSGID등이 있다.

  2) State

     태스크의 생성부터 소멸까지 태스크의 상태에 관한 변수다.

     Ex) TASK_RUNNING(0), TASK_INTERRUPTIBLE(1), TASK_UNINTERRUPTIBLE(2), TASK_STOPPED(4), TASK_TRACED(8), EXIT_DEAD(16), EXIT_ZOMBIE(32)

  3) Task relation

     Task의 가족 관계를 나타내는 구조체, 변수들이 포함된다.

     현재 태스크를 생성한 부모 태스크의 task_struct를 가르키는 real_parent와 현재 현재

부모 태스크의 task_struct를 가르키는 parent 필드가 존재한다. 또한 자식과 형제 관계인 children, sibling는 그 관계를 리스트로 저장한다.

모든 리눅스 커널의 태스크들은 init_tastk로부터 시작해, 이중 연결리스트로 연결되어 있으며, task_struct 구조체의 tasks라는 리스트 헤드를 통한다. 또한 RUNNING 상태인 태스크들은 run_list필드를 통해 따로 연결되어 있다.

4) Scheduling information

스케쥴링과 관련이 있는 변수. Prio, policy, cpus_allowed, time_slice, rt_priority등이 있다.

5) Signal information

태스크에게 비동기적[8] 사건을 알리는 매커니즘.

Signal, sighand, blocked, pending

6) Memory information

Memory context에 관한 크기, 접근, 제어에 관한 정보 등을 관리하는 변수들이 있다.

7) File information

Task가 오픈한 파일들에 대한 변수다. Files_struct 구조체의 files 변수로 접근이 가능하며, inode는 fs_struct 구조체의 fs 변수로 접근이 가능하다.

8) Thread structure

문맥 교환을 실행할 때 태스크가 어디까지 실행이 되었는지 저장해두는 공간이다.

[8] 호출과 응답이 동시에 이뤄지지 않는 것.

9) Time information

태스크의 시작시간, 사용한 자원 시간 등등을 위한 변수로, start_time, real_start_time 등이 있다.

10) Format

다른 커널의 컴파일과 이진 포맷을 지원하기 위한 필드가 존재한다.

11) Resource limits

태스크가 사용할 수 있는 자원의 한계를 의미한다. rlim_max는 최대 허용 자원 수, rlim_cur는 현재 설정된 허용 자원 수를 의미한다.

- State transition

태스크가 생성되면 TASK_RUNNING 상태가 된다. 이 후에 스케줄러에서는 여러 태스크 중 실행시킬 태스크를 선택하여 수행시키기 때문에 TASK_RUNNING은 실질적으로 ready 상태와 running 상태 두가지로 분류할 수 있다. 실행중인 태스크가 상태전이를 할 수 있는 여러가지 경우가 있는데,

1) 태스크가 자신의 일을 다 끝내고 exit()을 호출하면 TASK_DEAD(EXIT_ZOMBIE) 상태로 전이된다. 이 상태에선 태스크에 할당되어 있던 대부분의 자원을 반납하고, 태스크가 종료된 이유, 자원 정보들을 유지한다. 이 후에 부모 태스크가 wait()등의 함수를 호출하게 되면 TASK_DEAD(EXIT_DEAD) 상태로 전이되어 태스크가 완전히 종료되게 된다. Wait()를 호출하기 전에 부모 태스크가 종료되면 init_task가 부모가 된다.

2) TASK_RUNNING(running) 상태인 태스크가 할당된 CPU를 모두 사용하거나 더 높은 우선순위를 가지는 태스크가 나타나면 TASK_RUNNING(ready) 상태가 된다.

3) SIGSTOP, SIGTSTP, SIGTTIN 등의 시그널을 받은 태스크는 TASK_STOPPED 상태로 전이된다. 이 후 SIGCONT 시그널을 받으면 다시 TASK_RUNNING(ready) 상태로 전이된다.

4) TASK_RUNNING(running) 상태의 태스크가 다른 요청을 기다려야하는 경우 TASK_INTERRUPTIBLE 등으로 전이된다. TASK_UNINTERRUPTIBLE은 시그널에 반응하지 않는다는 점에서 다르다. 하지만 중요한 SIGKILL에도 반응을 하지않으면 곤란하기에 TASK_KILLABLE이라는 상태가 추가되었다.

- 사용자 수준

  사용자가 만든 응용프로그램이나 라이브러리를 실행하고 있는 상태다.

  커널을 호출하지 않고 독립적으로 스케줄링이 이루어지기 때문에 이식성이 높다. 따라서 context switching이 일어나지 않기 때문에 overhead가 감소한다. 동일한 프로세스의 스레드 1개가 ready 상태가 되면 다른 스레드도 실행을 하지 못하게 되는 단점이 있다. 따라서 blocked를 사용하지 못하고 non_blocked를 사용해야하는 단점이 있다.

  사용자 영역의 쓰레드 n개가 커널 영역의 쓰레드 1개와 매칭된다.

- 커널 수준

  CPU에서 커널의 코드를 수행하고 있는 상태다. 사용자 수준과 커널 수준이 1대 1로 매칭이 된다. 쓰레드가 ready 상태가 되도 동일한 프로세스의 다른 쓰레드로 대체가 된다. 하지만 context switching이 많이 일어나기에 overhead가 더 많이 일어난다.

- 사용자 수준에서 커널 수준으로 전이할 수 있는 방법은 시스템 호출 사용과 인터럽트가 있다.

  커널 수준에서 실행되는 코드는 리눅스 그 자체다. 따라서 태스크가 생성되면 태스크별로 일정 크기의 stack을 할당한다. 따라서 시스템 호출이 일어나면 stack을 이용하여 작업을 처리해준다.

  또한 시스템 호출을 했다면 작업 후 원래 사용자 수준 실행 상태로 돌아가야 하는데, 그 전 작업 상황까지의 상태를 저장해놓는 공간을 pt_regs라고 한다.

- Runqueue & scheduling

  ■ Scheduling

  여러 개의 태스크 중에서 다음에 실행시킬 태스크를 선택하여 자원을 할당하는 과정을 일컫는다. 실시간 태스크[9]는 0 ~ 99 단계를 사용하며, 일반태스크는 100 ~ 139 단계를 사용한다. 실시간 태스크는 일반 태스크보다 항상 먼저 실행된다.

- 일반적으로 OS에서는 실행가능한 상태의 태스크를 자료 구조를 통해 관리하는데 이 자료 구조를 Runqueue라고 한다. 부팅 이후, CPU 별로 하나씩 유지된다. Task가 처음 생성되면 init_task를 헤드로 하는 이중 연결리스트에 연결되는데 이것을 tasklist라고 한다. TASK_RUNNING 상태가 되면 runqueue중 하나로 소속된다. 새로 생성된 태스크는 보통 부모 태스크의 runqueue로 삽입된다. 하지만 한쪽의 runqueue가 부하가 일어난다면 다른 runqueue로 이동시키기도 한다. 이런 이동은 비교적 같거나 가까운 도메인의 runqueue로 일어난다.

- FIFO, RR, DEADLINE

  실시간 태스크는 우선 순위 결정을 위해 rt_priority 필드를 사용한다.

  ■ RR

  동일 우선 순위를 가지는 태스크가 여러 개일 경우 타임 슬라이스를 기반으로 스케줄링이 된다.

  ■ FIFO

  동일한 우선순위를 가지는 태스크가 없을 경우, 우선 순위가 높은 태스크부터 수행된다.

  ■ DEADLINE

  현재시간 + runtime < deadline을 이용해, 새로운 DEADLINE 태스크의 완료 여부를 확정적으로 결정할 수 있다. 가장 가까운 DAEDLINE을 지닌 태스크부터 대상으로 선정하며, DEADLINE은 Red-Black tree에 의해 정렬된다.

---

[9] 시간적으로 여러 제약을 갖는 task

- 이러한 스케줄링은 태스크의 개수가 늘어날수록 스케줄링에 걸리는 시간이 길어졌기에 태스크에 대한 비트맵[10]이 생겨났다.

- 일반 스케줄링(CFS[11])

  CFS는 각 태스크의 CPU 사용시간이 같게 한다. N개의 태스크가 존재하면 정해진 시간을 N으로 나눠 할당해준다. 시간을 너무 촘촘히 나누면 context switching으로 인한 overhead가 일어날 가능성이 크기 때문에 시간 설정을 잘 해주어야 한다. 만약 태스크에 우선 순위가 있다면 그만큼 가중치를 두어 할당 시간을 늘려준다.

  스케줄링에는 vruntime이 사용된다. vruntime 또한 key값으로 하여 RBtree에 정렬된다.

  결과적으로 태스크가 생성되면 가장 작은 vruntime값을 가지게 되어 빠른 수행을 하게된다. vruntime값은 주기적으로 갱신되며, 가장 작은 vruntime을 갖는 태스크가 다음 수행을 하게 된다.

  스케줄러는 언터럽트 후에 need_resched 필드가 활성화되었거나, 현재 태스크가 타임 슬라이스를 모두 사용했거나, 태스크가 새로이 생겨나거나, 스케줄에 관련된 시스템 호출을 할 경우에 일어난다.

  또한 CFS는 한 프로세스의 CPU 점유를 막기위해 group scheduling을 지원한다.

---

[10] 태스크가 생성되면 비트맵에서 그 태스크의 우선순위에 해당하는 비트를 set하고, 우선 순위에 해당하는 queue에 삽입한다. 스케줄링을 할때에 가장 우선순위가 높은 큐에 있는 태스크들을 선택한다.

[11] Completely Fair Schedluer

- Context switch

  수행 중이던 태스크의 동작을 멈추고, 다른 태스크로 전환하는 과정을 context switch라고 한다.

  Kernel은 context switch가 일어나면 태스크가 그 시점에 어디까지 수행했는지, 현재 CPU의 register 값은 어떤지 저장해둔다(context save). 이런 값들은 thread_struct 필드에 저장된다.

  스케줄링과 context switch, save는 모두 커널 수준에서 동작한다. 따라서 context switch가 일어나면 사용자 수준에서 커널 수준으로 상태를 전이해야 하고, 태스크 A에 할당된 커널 스택에 CPU 레지스터 정보가 저장된다. 그 후 스케줄링을 통해 context switch를 하게 되면 thread_struct에 CPU register 정보를 저장하게 된다. 그 다음 실행될 태스크 B의 CPU register 정보를 복원하고, 커널 수준에서 작업이 모두 완료되었다면, B의 커널 스택에서 CPU정보를 복원한 후 사용자 수준으로 상태 전이를 하게 된다.

CH4

- Virtual memory(가상 메모리)

  가상 메모리는 실제 시스템에 존재하는 물리 메모리의 크기와 관계없이 가상적인 주소 공간을 사용자 태스크에게 제공한다. 32bits CPU의 경우 word의 크기가 32bits이기 때문에 표현할 수 있는 주소의 크기가 2^{32}(4GB)이고 64bits CPU의 경우 2^{64}(16EB)다. 따라서 32bits의 CPU인 경우 각 태스크마다 4GB의 메모리 공간을 가지고 있다고 생각할 수 있다.

  프로그램은 보조기억장치(HDD, SSD)에 저장이 되어있다가 실행이 될 때 주 기억장치(RAM)에 load(적재)가 되는데 프로그램의 크기가 RAM의 크기보다 크거나 여러 프로그램일 경우 문제가 발생할 수 있다. 따라서 태스크마다 가상 메모리를 지정해주고 프로그램이 실행될 때만 RAM에 laod가 된다. 즉, 여러 개의 프로그램이 돌아갈 경우 당장 실행되는 프로그램만 RAM에 적재가 되고, 큰 프로그램일 경우는 프로그램 하나일지라도 모든 부분이 한번에 실행되지는 않기 때문에 실행되고 있는 부분만 RAM에 load하는 방식으로 가상 메모리를 활용한다.

- Physical memory(물리 메모리)

  ■ SMP(Symmetric Multiprocessing)

  메모리 주소에 접근하는데 모든 프로세서가 같은 cost를 같는 멀티프로세서를 의미한다. 초기에는 cache가 없는 SMP 구조였지만 각 프로세서가 같은 bus를 사용하기 때문에 data traffic을 줄이고 속도를 향상시키기 위해 각 프로세서마다 cache가 있는 형태로 발전했다. UMA(Unified Memory Access)라고 불리기도 한다.

  ■ NUMA(Non-Unified Memory Access)

  NUMA는 멀티프로세서에서 메모리 접근 시간이 로컬 메모리와 프로세서 간의 관계에 의존적인 것을 말한다. 프로세서는 자신의 로컬 메모리에 다른 메모리 접근이 빠르다. NUMA에는 특정 프로세서의 과부하를 줄이고, 태스크와 데이터 간 관련성을 알 수 있다는 장점이 있다.

- Node

  리눅스에서는 접근 속도가 같은 메모리의 집합을 bank라고 하는데 이 bank를 표현하는 구조를 Node라고 한다. 하나의 Node는 pg_data_t 구조체로 표현된다.

- Zone

  Zone은 유사한 속성의 페이지 프레임들의 집합이다.

  ISA 버스[12] 기반의 디바이스는 동작을 하기 위해 물리메모리 중 16MB 이하 부분을 할당해줘야 하는 경우가 있다. ISA 버스 구조에서도 원활히 리눅스가 수행되기 위해 16MB 이하의 부분을 따로 관리할 수 있도록 하는 자료 구조를 zone이라고 한다. 리눅스에서 16MB 이하의 메모리는 ZONE_DMA라 하고, 이상의 메모리를 ZONE_NORMAL이라고 한다.

  32bit system에서는 리눅스 커널은 1GB의 가상 공간을 차지한다. 따라서 물리 메모리가 1GB가 넘어간다면 1대 1로 매핑할 수 없다. 따라서 물리 메모리가 1GB 이상이라면 896MB(아키텍쳐마다 다르다.)는 물리 메모리와 1대 1로 매핑해주고 그 이상은 필요할 때 동적으로 물리 메모리에 할당해준다. 1대 1로 매핑되는 부분을 ZONE_NORMAL이라 하고, 그 이상의 부분을 ZONE_HIGHMEM이라 한다. 1대 1로 물리 메모리와 매핑되는 ZONE_DMA, ZONE_NORMAL은 커널 메모리 할당 시 가장 빠르게 접근할 수 있는 영역이다. 또한 32bit에서는 영역의 크기가 제한되어 있기 때문에 cost가 비싼 영역이고 물리 메모리가 할당될 때, ZONE_HIGHMEM이 모두 소진된 후에 할당이 된다.

  64bit system인 경우, 가상 메모리가 모든 물리 메모리 영역에 1대 1로 할당이 될 수 있기 때문에 ZONE_HIGHMEM을 따로 만들지 않는다.

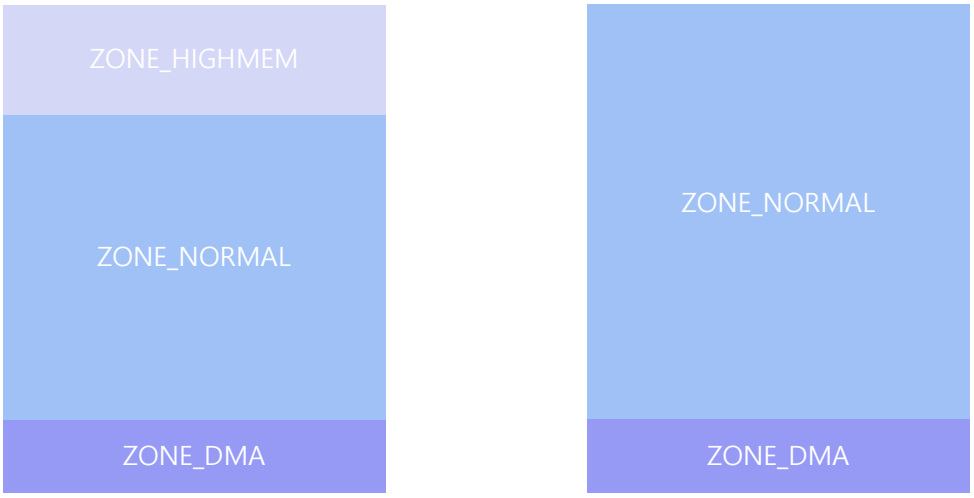

32bit system　　64bit system

  또한 ZONE이 꼭 여러 개가 존재해야 하는 것이 아니라 아키텍쳐에 따라 1개만 존재할

[12] CPU와 주변 디바이스와의 연결을 위한 16bit 버스 구조이다. 최근에는 32bit, 64bit의 디바이스가 많이 나와, 사라지고 있는 추세이며 PCI 버스로 교체되고 있다.

수도 있다.

또한 ZONE_MOVABLE, ZONE_DEVICE 영역도 존재한다. ZONE_DEVICE는 ZONE_DMA와 다르게 CPU에서 대용량 디바이스 메모리(PMEM[13], HM)에 접근하여 사용하기 위한 영역이다.

- Page frame

  물리 메모리의 최소 할당 단위를 페이지 프레임이라고 한다. (가상 메모리의 최소 할당 단위는 페이지) 즉, 여러 개의 페이지 프레임이 ZONE을 구성하며, 하나 이상의 ZONE이 Node를 구성하고, Bank[14]의 개수(UMA or NUMA)에 따라 하나 이상의 Node가 리눅스 전체 물리 메모리를 관리한다.

[13] 메모리 버스에 상주하는 SSD라고 볼 수 있다. 메모리 버스에서 DRAM과 동일한 성능을 가진다. 즉, DRAM과 동일한 빠르기를 가진 비휘발성 메모리라고 할 수 있는데, DRAM보다 싸고, 크며, 영구적이라는 장점이 있다. 또한 PCI Express의 cache로 사용될 수 있다.

[14] 접근 속도가 같은 메모리 집합

- Buddy allocator

  메모리 부하와 외부 단편화를 해결하기 위해 도입되었다.

  Buddy 할당자는 ZONE 구조체에서 free_area[] 배열에 의해서 구축된다. Free_area는 10개의 엔트리를 가지고 있는데 free_area가 관리하는 할당의 크기를 나타내며, 즉, 4MB(2^10 * 4KB)까지 할당할 수 있다. Free_area 구조체는 free_list와 map을 통해 할당된 페이지 프레임을 list와 bitmap으로 관리한다.

  예를 들어 색으로 칠해진 페이지 프레임들을 사용하고 있고 나머진 free 상태라 볼 때, 색으로 칠해진 비트가 할당되고, 색으로 칠해진 비트가 해제되었다고 하면,

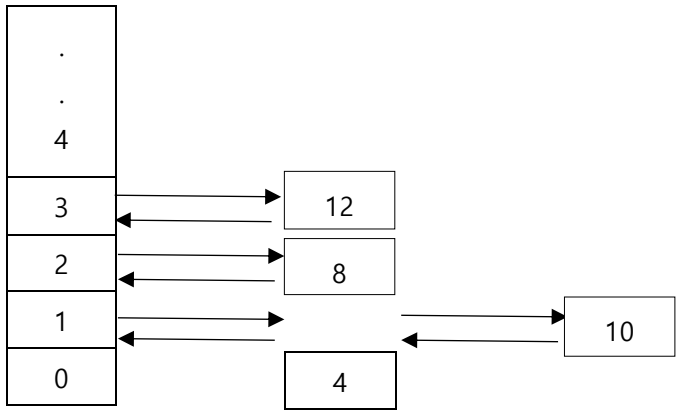

<free_list>

Pages	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
order(0)	0		0		1->0		0		0		1		0		0	
order(1)	0				0 -> 1				1 -> 0				0			
order(2)	0								1							
order(3)	0															

<bitmap>

Order(0)는 free_area[0]와 같은데, order(n)은 연속된 2^n개의 페이지 프레임이 free 상태로 존재하는지를 나타내 준다. 예를 들어 2개의 연속된 페이지 프레임을 할당받아야 할 때, 비트맵에서 order(1) 부분을 확인해 1로 된 부분이 있으면 bitmap을 0으로 수정하고 할당해 준다. 만약 없다면, 보다 큰 order(n)에서 연속된 2^n개의 페이지 프레임을 분할해, 할당하고 bitmap을 수정해준다. 이때, 나누어진 두 부분을 buddy라고 부르며 이때문

에 buddy allocator라고 부른다. 해제할때도 마찬가지로, 해당 부분을 해제하고 bitmap을 수정해준다.

- Lazy buddy

  Lazy buddy는 할당과 해제로 인한 오버헤드를 줄이기 위한 할당자 구조다. Buddy는 ZONE마다 유지되고 있는 watermark의 값과 사용가능한 페이지 프레임 수를 비교한다. 가용 메모리가 충분한 경우 페이지 병합 작업을 최대한 미루고 메모리가 부족해질 때 병합 작업을 수행한다.

  메모리를 반납하는 함수는 __free_pages()이고, 할당하는 함수는 __alloc_pages()다. __free_pages() 함수는 내부적으로, MAX_ORDER(위에서는 10)만큼 loop를 돌며, 해제된 해당 페이지 프레임이 버디(옆 메모리)와 합쳐져 상위 order에서 관리될 수 있는지 확인하고, 가능하다면 order의 nr_free를 변경해준다.

- Slab[15] allocator

  프레임 페이지보다 작은 메모리를 요청한다면? 그래도 최소 1개의 페이지 프레임을 할당해줘야 하는 내부 단편화가 발생한다. 따라서 slab allocator가 도입되었다.

  미리 몇 개의 페이지 프레임을 할당받아 자주 할당되는 크기로 분할해 둔다. 따라서 페이지 프레임보다 작은 메모리가 할당 요청을 받을 시 buddy가 아니라 slab에서 메모리를 할당해주고 해제받는다. 일종의 cache처럼 사용되는 메모리 관리 정책을 slab allocator라고 한다. Cache는 커널 내부에서 자주 할당되는 크기를 가지고 있고, cache가 여러 개의 slab으로 이루어져 있으며, slab은 다시 객체로 구성된다. Slab은 상태에 따라 free, partial, full로 구성되며, slab allocator에서 적당한 크기의 cache에서 객체를 할당해준다.

  Cache를 효율적으로 관리하기 위해 kmem_cache라는 자료 구조가 정의되어 있다. 이 구조체는 각각의 cache가 가진 객체의 크기를 표현한다. Slab allocator로부터 객체를 할당받는 함수는 kmem_cache_alloc()이고, 해제하는 함수는 kmem_cache_free()다. Cache가 꽉 찼다면 slab allocator는 buddy allocaotr로부터 kmem_cache_grow()함수를 호출해 더 할당받는다.

  하지만 slab은 많은 cache와 그에 따른 메타 데이터 때문에 필요 이상의 메모리를 필요로 하는 경우가 있다. 따라서 이를 보완하기 위해, Slub allocator가 개발되었다. Slub으로 할당된 객체들은 다음 같은 slub내의 다음 free 객체에 대한 포인터를 직접 포함한다. 또한 slub의 메타 데이터는 page 구조체 내부에 존재해, 별도의 메모리를 낭비하지 않는다.

---

[15] http://studyfoss.egloos.com/5332580

또한 동일한 크기의 객체에 대한 cache는 통합하여 관리하기에 데이터 효율을 높였다. 하지만 page 구조체가 지저분해지는 단점이 존재했다.

Slob은 slub의 overhead도 줄이기 위한 방법이다. (주로 메모리의 효율적인 사용이 중요한 곳에서 사용) 페이지를 작은 단위로 나눠, 이를 블록으로 묶어서 수행하는 방식이다. Slab이나 Slub과 다르게 특정 객체를 위한 것이 아니라 일정한 크기 내의 모든 할당 요청을 처리한다. First-fit[16] 알고리즘을 사용한다. 구조체의 경우 slub과는 다르게 slob_page 구조체를 따로 만들고 page 구조체와 연결하여, 필요한 필드에만 접근할 수 있도록 하였다.

- Virtual memory

Task_struct 구조체에서 메모리 관련은 mm_field 에 있다.

mm_struct 는 region[17]을 관리하고 RBtree 로 연결되어 있는 vm_area_struct, 주소 변환을 위한 pgd, 가상 메모리를 위한 변수들을 갖는다.

가상 메모리에서 변수들은 그림과 같이 0 번지부터, start_code, end_code, start_data, end_data, start_brk, brk(heap 영역의 끝)로 구성되어 있으며, stack 은 kernel 의 아래부분부터, 환경변수와 초기인자 이후부터 아래로 커진다.

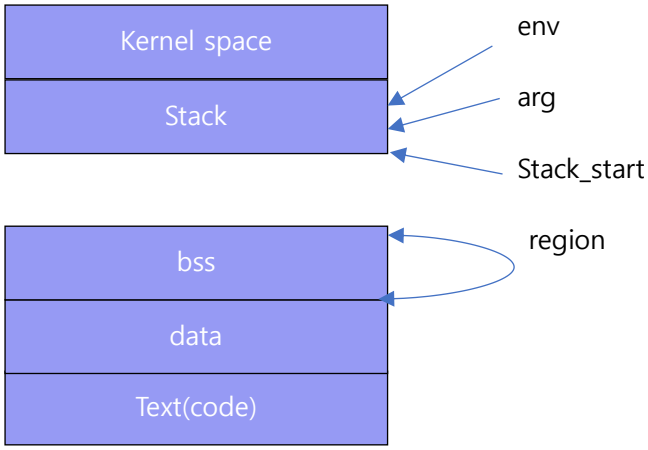

[16] 페이지를 하나의 블록으로 구성한 뒤 요청받은 크기만큼 할당해주고, 나머지를 다시 새로운 블록으로 구성한다. 중간에 할당되었던 블록이 해제되면 다음 free블록까지의 정보를 0,1번 unit에 저장하여, free_block_list를 구성한다.

[17] 가상 메모리 공간 중 속성이 같고 연속인 공간

가상 메모리 역시 page 가 모여, vm_area 를 구성하고, vm_area_struct 로 관리한다.

- vm_area(VMA)는 하나의 태스크에 여러 개가 존재할 수 있다. VMA 는 겹치지않으며, 서로 인접할 경우 하나로 생각해 처리할 수 있다.

- 물리 메모리와 가상 메모리의 변환

  기본적으로 디스크의 파일 실행은 태스크를 할당하고 ELF 의 포맷 구조에 따라 정해진 부분은 물리 메모리에 할당해주고, 약속된 가상 주소에 나머지를 연결시켜주는 것이다. 리눅스 커널은 페이지들을 페이지 프레임에 적재할 때, page table 을 같이 만들어 주소 변환에 이용한다. 즉, sys_execve() 시스템 호출이 파일의 일부를 읽을 때, free 한 페이지 프레임들을 할당받고, page talble 을 만들어, 가상 메모리와 연결한다. 그 후 태스크를 수행할 때 page table 을 따라 주소 변환을 실시한다.

  가상 주소를 물리 주소로 변환하는 과정을 paging 이라고 한다. Paging 은 가상 주소 번지를 페이지의 크기로 나누고, 그 몫을 page table 의 entry 로, 나머지를 index 로 하여 물리 주소를 찾는다. 물리 메모리에 적재가 되지 않은 주소는 page fault 가 발생하여 page_fault_handler 가 호출된다. Handler 는 free 한 페이지 프레임을 할당받아 해당 프레임을 읽어 load 시킨다.

- 리눅스에서는 원활한 paging 작업을 위해 paging 을 3 단계로 나눴다.

  가상 주소 공간을 이용하여 paging 을 하게 되는데, mm_struct 에서 PGD -> PMD -> PTE -> 실제 물리 메모리 주소의 과정을 거쳐 변환한다.

  실제 CPU 의 경우 대부분 주소 변환을 지원하는 MMU 를 가지고 있다.

APPENDIX

A. Difference of kernel space, user space

RAM 은 User space 와 Kernel space 두 부분으로 나뉘어 있다.

User space 는 일반적인 사용자 프로세스(프로그램)가 돌아가는 영역이다. 프로세스는 커널에 직접적으로 접근할 수 없다.

하지만 Kernel space 에서는 System call 을 호출해 kernel 에 접근할 수 있다. System call 은 kernel 에서 software interrupt 처럼 동작한다.

커널은 메모리의 일부분에서 실행되는데 User space 의 application/process 를 관리하는 역할을 해준다. System call 을 통해 interrupt 가 Kernel 에 보내지면 적당한 interrupt handler 가 역할을 수행한다.

B. Type of Memory, RAM

- ROM: Read Only Memory 로써, 한번 쓰면 수정이 불가능하다. 하지만 읽는 속도가 빠르기 때문에 바뀌지 않고 지워지면 안되는 곳에 사용한다.
- EPROM: ROM 과는 다르게 프로그래밍이 가능하지만(자외선을 이용해서 지움), 내용을 삭제하려면 칩을 빼줘야 한다.
- EEPROM: EPROM과는 다르게 보드에서 빼지 않고도 삭제가 block단위로 가능하다. 하지만 용량이 작고 느리다

- SRAM(Static RAM): transister가 6개가 사용되는 flip-flop에 bit를 저장한다. 전원이 유지되면 내용이 유지되며, 집적도가 DRAM에 비해 떨어지지만 속도가 빨라, cache에 사용된다.
- DRAM(Dynamic memory): transistor 1개와 축전기 1개로 구성되어있으며, 축전기에 전하의 형태로 bit가 저장된다. 집적도가 SRAM에 비해 뛰어나지만, 축전기에 전하가 방전이 되기 때문에 주기적으로 refresh를 해주어야 한다.

- Flash Memory: Cell transister라고 불리는 MOSFET(정확히는 MOS의 floating gate)에 전하를 축적하여 데이터를 보존한다. 축적된 전하는 산화막에 갇혀 비휘발성을 지닌다.
  - NAND: 직렬 연결 방식이고, 집적도가 높아, 대용량으로 만들기 쉽다. 읽을 때 Random Access가 불가능하기 때문에 읽기속도에 비해 쓰기/지우기 속도가 빠르다.

    직렬 연결 방식이기 때문에 지우거나 쓸 때 block 단위로 수행을 해야하며, 한 부분이라도 고장이 나면 전체를 바꿔야하는 매커니즘이 NAND와 비슷해, NAND FLASH MEMORY라고 불린다.
  - NOR: 병렬 연결 방식이고, 집적도가 낮다. 읽기속도는 빠르나, 쓰기/지우기를 할 때, 속도가 느리다. 프로그램의 bit화가 가능하기에 NOR FLASH MEMORY라고 불린다.

C. Memory Access in hardware

메모리에서 locality(접근성)는 크게 두가지로 나뉜다.

1) Temporal(시간적 접근성): 최근에 쓴 데이터를 다시 쓸 확률이 높다.

2) Special(공간적 접근성): 인접해 있는 데이터에 접근할 확률이 높다.

또한 CPU에서 메모리를 참조할 때의 관계는

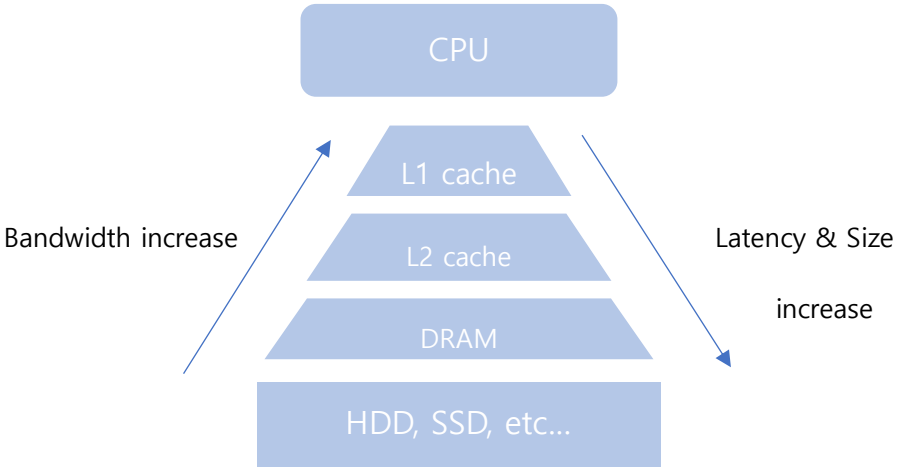

RAM architecture에서 CPU의 RAM으로의 데이터 추출 과정은 다음과 같다.

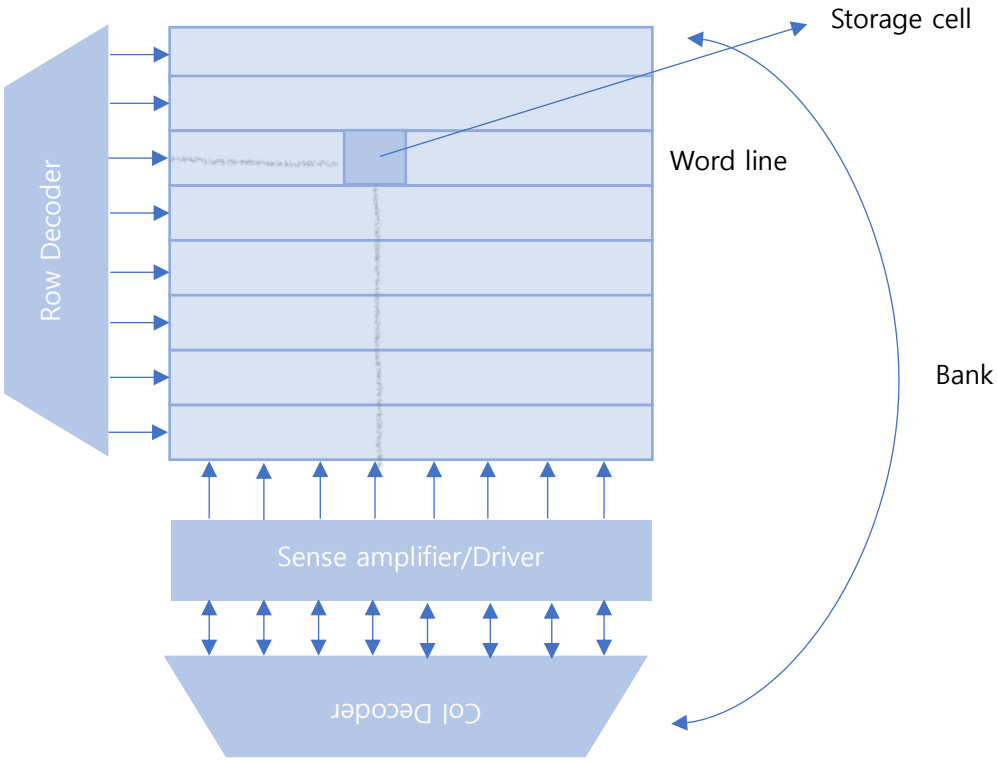

1) CPU가 메인보드에 데이터 요청
2) Chip set이 데이터의 행 주소를 메모리에 전송
3) 메모리의 행 주소 버퍼에 주소가 들어오면 sense amp가 행의 모든 cell을 읽음 (RAS, Row Access Stobe)
4) 열 주소를 버퍼에 받고 해당 cell을 읽음 (Column Access Stobe)
5) 읽은 데이터를 출력 버퍼에 load
6) 메인보드의 chip set이 내용을 읽고 CPU에 전달

따라서 위해 이전의 데이터 같은 행에 있는 데이터를 요청할 시 RAS-CAS latency가 줄어들어, 데이터를 읽는 속도가 더 빠르다. (CAS과정만 하면 되기 때문이다.)